Eco-asistente

Guía completa: funcionamiento, aprendizaje y lectura de los gráficos

Respuesta corta: sí, el modelo aprendió asociaciones útiles entre palabras y categorías. No entiende los residuos como una persona: la app combina el modelo con coincidencias y reglas explícitas.

714	648	92,2 %	87,0 %
filas del CSV principal	descripciones distintas	exactitud mostrada por la app	exactitud al quitar duplicados exactos

Qué dicen estas cifras

La app evalúa el clasificador principal con 179 ejemplos reservados: acertó 165 y se equivocó en 14. Eso muestra aprendizaje, pero la cifra de 92,2 % puede ser optimista: el CSV tiene 66 filas repetidas y 28 descripciones exactas aparecen tanto en entrenamiento como en prueba. En una comprobación adicional, quitando repetidos exactos antes de separar los datos, la exactitud fue 87,0 % (141 de 162). Aún pueden quedar frases muy parecidas entre ambos grupos.

Distribución actual del CSV principal

Categoría	Ejemplos	Color del contenedor
orgánico	**188**	marrón
papel y cartón	**162**	azul
resto	**139**	gris
envases	**119**	amarillo
vidrio	**106**	verde

Las 648 descripciones únicas no están distribuidas por igual. Orgánico tiene más filas; vidrio tiene menos. La orientación no es una garantía para residuos nuevos.

1. Cómo funciona la app

Una consulta puede pasar por reglas directas o por el modelo, según el texto que escribas.

Paso	Qué ocurre	Ejemplo
Coincidencia exacta	Busca el texto en dataset_eco_asistente.csv y devuelve la categoría guardada.	Una descripción ya etiquetada.
Casos especiales	Algunos términos explícitos muestran el aviso de punto limpio.	Pila o medicamento.
Envase ambiguo	Si falta el material de un envase, pide más detalles; vidrio/cristal y plástico/metal llevan a categorías distintas.	“Botella de tomate” pide material.
Frutas y vegetales	Una lista de términos en app.py reconoce alimentos comunes y los asigna a orgánico. Es una regla programada, no un aprendizaje del modelo.	“Plátano” -> fruta -> orgánico.
Modelo de texto	Para otros textos reconocidos, clasifica usando patrones de palabras aprendidos en el CSV principal.	“Frasco de vidrio” -> vidrio.
Sin pista suficiente	Si no encuentra coincidencia, regla o palabras conocidas suficientes, informa que no reconoce la entrada.	Una descripción fuera del vocabulario.

Qué aprende el modelo

Herramienta	En palabras simples
CountVectorizer	Convierte cada descripción en números según las palabras que contiene.
LogisticRegression	Aprende qué palabras suelen aparecer en cada categoría y usa esas asociaciones para elegir una.
Prueba reservada	Separa ejemplos antes de entrenar para medir predicciones en textos que no usó esa parte del entrenamiento.
Modelo final	Después de evaluar, vuelve a entrenarse con todas las filas del CSV principal para atender consultas.

Qué significa “aprendió”

Aprendió patrones de vocabulario, no conceptos del mundo. Por ejemplo, asocia muchas descripciones con “botella de vidrio” a vidrio, pero no sabe por sí mismo que una banana es fruta. En la app actual, banana se reconoce porque aparece en la lista de frutas programada en app.py. Por eso, algunos aciertos vienen del modelo y otros de reglas.

datos/teste.csv se usó para experimentar con el campo tipo, pero no forma parte del entrenamiento de la app actual.

2. Cómo leer los gráficos

El panel de análisis describe el dataset y una evaluación reservada. No se actualiza con cada búsqueda.

Ejemplos por categoría

Cada barra cuenta filas de esa categoría en el CSV principal. No representa cuántas veces se ha usado la app ni cuántos residuos se han consultado. Las barras usan colores asociados a los contenedores.

Aciertos y errores

Este gráfico resume el conjunto reservado: para cada categoría real, muestra cuántos ejemplos clasificó bien y cuántos confundió. Sirve para detectar dónde falla más. La muestra actual tiene 179 filas.

Matriz de confusión del clasificador principal

Las filas son la categoría correcta del ejemplo; las columnas, la predicción. La diagonal contiene aciertos. Los números fuera de la diagonal muestran las confusiones.

Real / predicha	envases	orgánico	papel y cartón	resto	vidrio
envases	25	4	1	0	0
orgánico	0	46	0	1	0
papel y cartón	0	0	41	0	0
resto	2	2	3	28	0
vidrio	0	1	0	0	25

Ejemplo: de los 30 envases reales, 25 quedaron bien; cuatro se predijeron como orgánico y uno como papel. De los 35 casos reales de resto, 28 quedaron bien; los demás se repartieron entre envases, orgánico y papel.

La matriz es fija porque compara etiquetas reales con predicciones de una prueba preparada al cargar los datos. Al escribir “plátano” o “vidrio”, no hay una etiqueta real nueva para añadir. Para reflejar búsquedas recientes habría que guardar un historial y confirmar la categoría correcta.

La matriz evalúa el modelo de texto. Las reglas de frutas/vegetales y envases se aplican durante la consulta, pero no forman parte de esta matriz.

3. Experimento adicional: el campo tipo

Se probó si el modelo podía predecir primero fruta, vegetal, envase ligero y otros tipos, usando datos/teste.csv.

84	63 / 21	14 / 21	66,7 %
filas sin vacíos ni repetidos exactos	entrenamiento / prueba	aciertos en la prueba	exactitud

Tipo	Aciertos / prueba	Recall en esta muestra
envase de vidrio	**3/3**	100 %
envase ligero	**1/3**	33 %
fruta	**3/3**	100 %
objeto no envase	**2/3**	67 %
otro alimento	**2/3**	67 %
papel o cartón	**3/3**	100 %
vegetal	**0/3**	0 %

Qué nos enseñó

El 66,7 % es una primera señal, no una medida estable: hubo solo tres filas de prueba por tipo. El modelo confundió las tres verduras reservadas con fruta y dos de las tres envases ligeros con otro alimento. La distinción fruta/vegetal no está suficientemente aprendida.

Decisión actual

Mantener las cinco categorías de reciclaje como predicción principal. La columna tipo puede ayudar a explicar un residuo, pero no conviene tratarla todavía como un segundo clasificador fiable. Para frutas y vegetales comunes, la app usa una lista explícita; para los demás casos utiliza el clasificador principal y reglas de envase.

En resumen: el modelo principal sí aprendió asociaciones útiles y muestra buen resultado en su prueba aleatoria, aunque los duplicados pueden inflar la cifra. El experimento de tipo mostró límites claros y no justifica reemplazar el diseño de cinco categorías.

Para mejorar la evaluación: quitar duplicados antes de dividir; mantener frases muy parecidas juntas en el mismo grupo; ampliar ejemplos variados en las clases con errores; y reservar ejemplos realmente nuevos para una prueba final.